

07

Régression logistique

Automne 2026

Techniques d'apprentissage automatique — 420-C74-SF — gr. 10017
Spécialiste en solutions d'intelligence artificielle — M. Swawola, M.Sc.

**NOUS ÉCLAIRONS.
VOUS BRILLEZ.**

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES



Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Introduction à la classification

- En **classification**, la variable réponse est une **variable discrète** (ou qualitative)
- Exemples
 - Transaction sur une carte de crédit: normale ou **frauduleuse** ?
 - Présence d'une tumeur: bénigne ou **maligne** ?
 - Image sur le web: authentique ou **deepfake** ?


Introduction à la classification

- En **classification**, la variable réponse est une **variable discrète** (ou qualitative)
- Exemples
 - Transaction sur une carte de crédit: normale ou **frauduleuse** ?
 - Présence d'une tumeur: bénigne ou **maligne** ?
 - Image sur le web: authentique ou **deepfake** ?
- **Classification binaire** = deux catégories ou **classes**
 $y \in \{0, 1\} \rightarrow$ classe négative (0) - **classe positive** (1)

Introduction à la classification

- En **classification**, la variable réponse est une **variable discrète** (ou qualitative)
- Exemples
 - Transaction sur une carte de crédit: normale ou **frauduleuse** ?
 - Présence d'une tumeur: bénigne ou **maligne** ?
 - Image sur le web: authentique ou **deepfake** ?
- **Classification binaire** = deux catégories ou **classes**
 $y \in \{0, 1\} \rightarrow$ classe négative (0) - **classe positive** (1)
- **Classification multiclass** = plus de deux classes
 $y \in \{0, 1, 2, 3, \dots\}$
- Exemple: [détection de rétinopathie diabétique](#) (échelle de 0 à 4)


Exemple #1 - Classification des transactions




Transactions sur une carte de crédit (données simulées)

Question

- Vous l'aurez peut-être remarqué, les données précédentes manquent de réalisme ... selon vous, quels seraient deux “aspects” à changer afin que les données représentent plus fidèlement des transactions bancaires réelles ?






Exemple #1 - Classification des transactions



Transactions sur une carte de crédit (données simulées)


Exemple #2 - Classification des paiements à temps



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

La régression linéaire fonctionne t-elle ?

- Utilisation de la régression linéaire dans un contexte de classification
 - Comment choisir le **seuil** ?
 - Signification des **valeurs négatives** ?
 - **Pente** de la droite ?




Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

La régression linéaire fonctionne t-elle ?

■ Utilisation de la régression linéaire dans un contexte de classification

- Comment choisir le **seuil** ?
- Signification des **valeurs négatives** ?
- **Pente** de la droite ?


La régression linéaire n'est pas adaptée à la classification !



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Introduction à la classification


- La **régression logistique** est un modèle de **classification**
- $y \in \{0, 1\}$
- $0 \leq h_{\theta}(x) \leq 1$



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Introduction à la classification

- La **régression logistique** est un modèle de **classification**
- $y \in \{0, 1\}$
- $0 \leq h_{\theta}(x) \leq 1$
- Il existe de nombreux autres modèles pour effectuer les tâches de classification (SVM, arbres, réseaux de neurones, etc ...)



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Question

■ Quelle(s) affirmation(s) est(sont) vraie(s) ?

1. Si la régression linéaire ne fonctionne pas sur une tâche de classification comme montré précédemment, effectuer une mise à l'échelle ou une standardisation du jeu de données peut aider
2. Si le jeu de données satisfait $0 \leq y^{(i)} \leq 1$ pour chaque exemple $(x^{(i)}, y^{(i)})$, alors la prédiction d'une régression linéaire satisfera $0 \leq h_{\theta}(x) \leq 1$ pour toute valeur de x
3. Pour toute variable explicative x prédisant parfaitement y tel que $y = 1$ si $x \geq c$ et $y = 0$ si $x < c$, alors la régression linéaire ne fera aucune erreur de classification
1. Aucune des affirmations ci-dessus n'est vraie

Réponse

■ Quelle(s) affirmation(s) est(sont) vraie(s) ?

1. Si la régression linéaire ne fonctionne pas sur une tâche de classification comme montré précédemment, effectuer une mise à l'échelle ou une standardisation du jeu de données peut aider
 2. Si le jeu de données satisfait $0 \leq y^{(i)} \leq 1$ pour chaque exemple $(x^{(i)}, y^{(i)})$, alors la prédiction d'une régression linéaire satisfera $0 \leq h_{\theta}(x) \leq 1$ pour toute valeur de x
 3. Pour toute variable explicative x prédisant parfaitement y tel que $y = 1$ si $x \geq c$ et $y = 0$ si $x < c$, alors la régression linéaire ne fera aucune erreur de classification
1. Aucune des affirmations ci-dessus n'est vraie

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Représentation du modèle de régression logistique

■ Modèle de régression logistique

$$0 \leq h_{\theta}(x) \leq 1$$

⋮



$$h_{\theta}(x) = g(\theta^T x)$$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x^n)$$



Représentation du modèle de régression logistique

■ Modèle de régression logistique


$$0 \leq h_{\theta}(x) \leq 1$$



$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$$



$$g(z) = \frac{1}{1+e^{-z}}$$



Représentation du modèle de régression logistique

■ Modèle de régression logistique

$$0 \leq h_{\theta}(x) \leq 1$$




$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$$



$$g(z) = \frac{1}{1+e^{-z}}$$

■ Fonction **logistique** ou **sigmoïde**




■ Asymptotes

$$\lim_{z \rightarrow +\infty} g(z) = 1$$

$$\lim_{z \rightarrow -\infty} g(z) = 0$$

Interprétation du modèle

- $h_{\theta}(x)$ représente une estimation de la probabilité que y soit égale à 1 pour l'exemple x




Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Interprétation du modèle

- $h_{\theta}(x)$ représente une estimation de la probabilité que y soit égale à 1 pour l'exemple x
- Par exemple, si $x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{Balance} \end{bmatrix}$

alors $h_{\theta}(x) = 0.6$ signifie que la probabilité de défaut de paiement est de 60 %




Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Interprétation du modèle

- Probabilité que y soit égal à 1 sachant x et paramétré par θ

$$h_{\theta}(x) = P(y = 1|x; \theta)$$



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Interprétation du modèle

- Probabilité que y soit égal à 1 sachant x et paramétré par θ

$$h_{\theta}(x) = P(y = 1|x; \theta)$$


- La somme des probabilités de toutes les possibilités est égale à 1. Puisque $y \in \{0, 1\}$ alors

$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$

$$P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$$

ou

$$P(y = 1|x; \theta) = 1 - P(y = 0|x; \theta)$$



Jeu de données **Default**. Défauts de paiement selon le revenu annuel et le solde mensuel des cartes de crédits des consommateurs^[3]

Question

- Supposons que nous voulions prédire à partir d'une nouvelle parue sur le web si celle-ci est une "fake news" ($y = 1$) ou une nouvelle authentique ($y = 0$). Notre classificateur basé sur la régression logistique prédit, pour la nouvelle en question $h_{\theta}(x) = P(y = 1|x; \theta) = 0.11$

Quelle est la probabilité que la nouvelle soit authentique ?

Réponse

- Supposons que nous voulions prédire à partir d'une nouvelle parue sur le web si celle-ci est une "fake news" ($y = 1$) ou une nouvelle authentique ($y = 0$). Notre classificateur basé sur la régression logistique prédit, pour la nouvelle en question $h_{\theta}(x) = P(y = 1|x; \theta) = 0.11$

Quelle est la probabilité que la nouvelle soit authentique ?

Il s'agit de $P(y = 0|x; \theta) = 1 - 0.11 = 0.89$


Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- **Frontière de décision**
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Frontière de décision

- Supposons que nous
prédisons $y = 1$ si $h_{\theta}(x) \geq 0.5$
alors


$$h_{\theta}(x) = g(\theta^T x) \geq 0.5 \Leftrightarrow \theta^T x \geq 0$$




Frontière de décision

- Supposons que nous
prédisons $y = 0$ si $h_{\theta}(x) < 0.5$
alors


$$h_{\theta}(x) = g(\theta^T x) < 0.5 \Leftrightarrow \theta^T x < 0$$



Frontière de décision



Frontière de décision



■ $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$

■ Prédiction de $y = 1$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 \geq 0$$


$$\theta_1 x_1 + \theta_2 x_2 \geq -\theta_0$$

■ Prédiction de $y = 0$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 < 0$$

$$\theta_1 x_1 + \theta_2 x_2 < -\theta_0$$

Frontières de décision non linéaires



■ $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$

■ Prédiction de $y = 1$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 \geq 0$$


$$\theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 \geq -\theta_0$$

■ Prédiction de $y = 0$ si

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 < 0$$

$$\theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 < -\theta_0$$

Frontières de décision non linéaires




- Idem que précédemment, avec un polynôme d'ordre 3 ...

Question


- Considérons une régression logistique incluant deux variables explicatives x_1 et x_2 . Supposons que $\theta_0 = 3$, $\theta_1 = -1$ et $\theta_2 = 0$ de telle sorte que $h_\theta(x) = g(3 - x)$

$$h(x)=y= g(3 -x_1)$$


Quelle figure suivante montre la frontière de décision de $h_\theta(x)$?




A



B



C




D


Réponse

- Considérons une régression logistique incluant deux variables explicatives x_1 et x_2 . Supposons que $\theta_0 = 3$, $\theta_1 = -1$ et $\theta_2 = 0$ de telle sorte que $h_\theta(x) = g(3 - x)$


Quelle figure suivante montre la frontière de décision de $h_\theta(x)$?




A



B



C



D

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- **Fonction de coût**
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Fonction de coût

- Exprimons la fonction de coût sous la forme

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{loss}(h_{\theta}(x^{(i)}), y^{(i)})$$

- Si


$$\text{loss}(h_{\theta}(x^{(i)}), y^{(i)}) = (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

alors la fonction de coût pour la régression logistique est **non convexe**



$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Question


- Parmi les fonctions de coût ci-dessous, lesquelles sont non convexe ?




A



B




C



D

Réponse


- Parmi les fonctions de coût ci-dessous, lesquelles sont non convexe ?




A



B



C




D

Fonction de coût

■ Fonction de perte en régression logistique

$$\text{loss}(h_{\theta}(x^{(i)}), y^{(i)}) = \begin{cases} -\log(h_{\theta}(x^{(i)})) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x^{(i)})) & \text{si } y = 0 \end{cases}$$




$$\lim_{z \rightarrow 0} -\log(z) = +\infty$$

Fonction de coût

■ Fonction de perte en régression logistique

$$\text{loss}(h_{\theta}(x^{(i)}), y^{(i)}) = \begin{cases} -\log(h_{\theta}(x^{(i)})) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x^{(i)})) & \text{si } y = 0 \end{cases}$$



$$\lim_{z \rightarrow 1} -\log(1 - z) = +\infty$$

Fonction de coût

- Pour résumer ...

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{loss}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{loss}(h_{\theta}(x^{(i)}), y^{(i)}) = \begin{cases} -\log(h_{\theta}(x^{(i)})) & \text{si } y^{(i)} = 1 \\ -\log(1 - h_{\theta}(x^{(i)})) & \text{si } y^{(i)} = 0 \end{cases}$$

$$\text{loss}(h_{\theta}(x^{(i)}), y^{(i)}) = -y^{(i)} \times \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \times \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

Entropie croisée
ou Log Loss



→ La fonction de coût ci-dessus est **convexe** !

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- **Algorithme du gradient**
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Algorithme du gradient

- Fonction de coût en régression logistique

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \times \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

Algorithme du gradient

- Fonction de coût en régression logistique

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \times \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

- On souhaite trouver les paramètres θ qui minimisent la fonction de coût

$$\min_{\theta} J(\theta)$$

Algorithme du gradient

- Fonction de coût en régression logistique

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \times \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

- On souhaite trouver les paramètres θ qui minimisent la fonction de coût

$$\min_{\theta} J(\theta)$$

- L'algorithme du gradient s'exprime alors sous la forme

Répéter jusqu'à convergence{

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \times x_j^{(i)} \quad \dots \quad \text{Identique à la régression linéaire ?}$$

}

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Algorithme du gradient

- Fonction de coût en régression logistique

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \times \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \times \log(1 - h_{\theta}(x^{(i)}))$$

- On souhaite trouver les paramètres θ qui minimisent la fonction de coût

Ne pas oublier la mise à l'échelle des variables explicatives !

- L'algorithme du gradient s'exprime alors sous la forme

Répéter jusqu'à convergence{

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \times x_j^{(i)} \quad \dots \quad \triangleright \text{Identique à la régression linéaire ?}$$

}


$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- **Métriques en classification**
- Classification multiclass
- Notions supplémentaires
- Lectures et références

Métriques en classification

Log loss

Accuracy

Precision / Recall

Sensitivity / Specificity

F-score

ROC / AUC

Métriques en classification

Log loss

Accuracy

Precision / Recall

Sensitivity / Specificity

F-score

ROC / AUC

Accuracy

- **Accuracy**

La précision est définie comme le rapport entre le nombre d'observations correctement classées et le nombre total d'observations

$$\text{accuracy} = \frac{1}{i} \sum_i I(h(x^{(i)}) = y^{(i)})$$

- Les autres métriques (ROC, F-score, ...) seront étudiées prochainement
- Attention à ne pas confondre **précision** (accuracy) et **précision** (precision) ...


Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- **Classification multiclass**
- Notions supplémentaires
- Lectures et références

Classification multiclass


■ Quelques exemples

- Prédiction météo: ensoleillé, nuageux, pluvieux, neigeux $\rightarrow$ 4 classes
- Sentiment des commentaires sur un produit: positif, négatif, neutre $\rightarrow$ 3 classes
- Thème d'un article de nouvelles: sport, économie, politique, ... $\rightarrow n$ classes



Classification multiclass

- Afin de pouvoir prendre en compte plusieurs classes, deux voies sont envisageables
 - Soit on apprend directement en multi-classes, dans ce cas la régression logistique ne fonctionne pas et il faut se rabattre sur un algorithme “naturellement” multiclasse (kNN, arbres, réseaux de neurones à plusieurs sorties, etc ...)
 - Soit on se ramène à deux classes: **OneVsRest** et **OneVsOne**



Classification multiclass

■ OneVsRest

Entraînement d'un modèle de régression logistique $h_{\theta}^{(c)}(x)$ sur chaque classe c afin de prédire la probabilité que $y = c$

Pour toute nouvelle donnée x , faire une prédiction sur chacun des classificateurs et choisir la classe c qui maximise

$$\max_c h_{\theta}^{(c)}(x)$$

Question

- Considérons un problème de classification à k classes. En utilisant la méthode **OneVsRest**, combien de classificateurs à régression logistique doit-on entraîner ?
 - A. $k - 1$
 - B. k
 - C. $k + 1$
 - D. Approximativement $\log_2(k)$

Réponse


- Considérons un problème de classification à k classes. En utilisant la méthode **OneVsRest**, combien de classificateurs à régression logistique doit-on entraîner ?
 - A. $k - 1$
 - B. k
 - C. $k + 1$
 - D. Approximativement $\log_2(k)$

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- **Notions supplémentaires**
- Lectures et références

Entropie, entropie croisée et divergence K-L

- Visionner la vidéo ci-contre (en anglais)




A Short Introduction to Entropy, Cross-Entropy and KL-Divergence - Aurélien Géron

Perceptron


- Considérons l'exemple d'une régression logistique à deux variables explicatives

$$h_{\theta}(x) = g(\theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2)$$

avec g étant la fonction logistique



Neuron




On obtient un **perceptron**, ou **neurone artificiel** !

Sommaire

- Introduction à la classification
- Représentation du modèle de régression logistique
- Frontière de décision
- Fonction de coût
- Algorithme du gradient
- Métriques en classification
- Classification multiclass
- Notions supplémentaires
- **Lectures et références**

Lectures et références



- Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani, Jonathan Taylor, **“An Introduction to Statistical Learning with Applications in Python”**
- 4.3 Logistic Regression

Lectures et références

- [1] CS229: Machine Learning - Stanford University
- [2] [A Short Introduction to Entropy, Cross-Entropy and KL-Divergence - Aurélien Géron](#)
- [3] Introduction to Statistical Learning with Applications in R
- [4] Classification et métriques d'évaluation, Université Laval